


上一堂課的延伸：

當 λ 值越大，**regression** 後會較穩定，但是 **bias**(偏移量)會較大，用之前學過的 **rLSE** 來想， λ 越大，**w**(係數)就會較小，就不會因為一兩筆資料而讓 **regression** 後的結果有大幅改變，但是這樣會讓 **regression** 後的結果離最佳的(**error** 最小)的 **w** 較遠，換句話說，若 λ 趨近於 0，就幾乎沒有誤差存在。

課本 p150


左欄是相同 λ ，由右欄的綠線加上 **error**，隨機產生多筆資料，而產生的 **regression** 結果




當 λ 越大，可看到多條紅線幾乎是重疊，不會有不穩定情形發生，但是隨之而來的就是誤差較大，可看到右圖，紅線和綠線差非常多。



當 λ 越小，不同的資料就會產生不同的結果，不會有不穩定情形發生，但是隨之而來的就是誤差較小，可看到右圖，紅線和綠線差不多。



舉個例子，就像是右圖，黑線是原始的 **model**，我們隨機產生兩筆有 **error**(藍點和紫點)的數據，當 λ 很小時，會產生幾乎沒有 **error** 的 **regression** 結果，但是不同筆 **data** 產生的 **regression** 結果會相差較大，也就是比較不穩定，當然，當取樣點越來越多時，**regression** 會越接近原始 **model**，但是那也要在我們取樣點夠多時才不會發生(和 **overfitting** 概念一樣)，詳細可見 **lesson1**



上圖是使用上堂課的 MAP 做 online learning 的示意圖，第一欄是 likelihood $P(D|\mathbf{w})$ ，第二欄是我們給定的 prior $P(\mathbf{w})$ ，第三欄是由 posterior $P(\mathbf{w}|D) = \frac{P(D|\mathbf{w})P(\mathbf{w})}{P(D)}$ ，產生出多個不同的 \mathbf{w} 而生成的多項式，在一開始時，我們假定的 prior 是沿著圓點放射出去的同心圓，也就是各個參數 w_i 的 variance 皆相同，此時我們幾乎沒有得到甚麼多餘的資訊。


舉個例來說我們在擲一個不知道公不公平的銅板，我們一開始假設正面機率是 0.5，當然，根據我們這個假設如果投擲 10 次，會得到各式各樣不同的結果，和這裡是一樣的概念。

第二列就是我們已經收到第一筆資料(最右邊圖上的藍圓圈)，根據這一筆資料我們可以根據上一次的 prior 可算得 likelihood，而由於 prior 是 multivariate Gaussian，likelihood 是 univariate Gaussian，我們不需要另外算 marginal，因為我們知道結果必為 multivariate Gaussian，就像是 conjugate 的 beta distribution 一樣，我們只需要更新 multivariate Gaussian 的 mean 和 variance 就好，如此我們可以得到第二欄的 posterior，以此當作第三欄的 prior。而因為我們資訊變多了，我們的 mean 和 variance 都會作些許移動，如果資訊沒有偏移太多，variance 理應來說會越來越小，由圖上也可清楚看到，第二列的 posterior 的光量比第一列還小，故若從這個 posterior 取出多組 \mathbf{w} 出來，其結果就會呈現如最右邊圖那樣，其直線都會較第一列直線接近。

第三列和第二列做一樣的事，重複得到 data 後可得到第四列的結果，可看到已經得到許多筆資料了(有很多藍圓圈)，因為都和之前分析的 mean 很接近，故可看到其 posterior 的 variance 非常小(幾乎沒有光量)。

Predictive distribution

我們固然可以用 MAP 一次一次的作 online learning，找出最有可能的 \mathbf{w} ，再用算出來的 posterior 求出一組 \mathbf{w} ，得到 \mathbf{y} ，但其實我們根本就不關心 \mathbf{w} 會怎麼樣，我們有興趣的只有 \mathbf{y} ，我這前面所做的都只有找出 \mathbf{w} 的機率，求 \mathbf{y} 時 \mathbf{w} 都已經給定，也就是 $P(\mathbf{y} | \mathbf{w}, \theta)$ ，我們其實最有興趣的應該是如同求出 \mathbf{w} 分布一樣，應該是想要 \mathbf{y} 的分布，也就是我們希望除了找出最有可能的直線外，我們也想知道“結果是其他條直線”的結果為何，和 \mathbf{w} 無關，也就是 $P(\mathbf{y} | \theta)$ ，也就是想得到這張圖



$$P(Y | \theta) = \int P(Y | \mathbf{w}, \theta) P(\mathbf{w}, \theta) d\mathbf{w}$$

其實就是 marginalize 接下來我們就要開始之前沒有推導完的，若 prior 是 multivariate Gaussian，posterior 是 univariate Gaussian，marginalize 後也還會是 multivariate Gaussian。

其中

$$P(Y | \mathbf{w}, \theta) \sim N(Y | X\mathbf{w}, a^{-1})$$

$$P(\mathbf{w}, \theta) \sim N(\mathbf{w} | \boldsymbol{\mu}, \Lambda^{-1})$$

$$\begin{aligned} & \int N(Y | X\mathbf{w}, a^{-1}) N(\mathbf{w} | \boldsymbol{\mu}, \Lambda^{-1}) d\mathbf{w} \\ &= \int e^{-\frac{a}{2}(X\mathbf{w}-Y)^2} e^{-\frac{1}{2}(\mathbf{w}-\boldsymbol{\mu})^T \Lambda (\mathbf{w}-\boldsymbol{\mu})} d\mathbf{w} \\ &= \int e^{-\frac{1}{2}a(X\mathbf{w}-Y)^T (X\mathbf{w}-Y) + \frac{1}{2}(\mathbf{w}-\boldsymbol{\mu})^T \Lambda (\mathbf{w}-\boldsymbol{\mu})} d\mathbf{w} \\ &= \int e^{-\frac{1}{2}(a(\mathbf{w}^T X^T X \mathbf{w} - 2\mathbf{w}^T X^T Y + Y^T Y) + (\mathbf{w}^T \Lambda \mathbf{w} - 2\mathbf{w}^T \Lambda \boldsymbol{\mu} + \boldsymbol{\mu}^T \boldsymbol{\mu}))} d\mathbf{w} \\ &= \int e^{-\frac{1}{2}(\mathbf{w}^T (aX^T X + \Lambda) \mathbf{w} - 2\mathbf{w}^T (aX^T Y + \Lambda \boldsymbol{\mu}) + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})} d\mathbf{w} \end{aligned}$$

一樣的，我們拿指數項出來看，試圖將其轉為 quadratic form

$$\begin{aligned} & (\mathbf{w} - \mathbf{m})^T C (\mathbf{w} - \mathbf{m}) \\ &= \mathbf{w}^T C \mathbf{w} - 2\mathbf{w}^T C \mathbf{m} + \mathbf{m}^T C \mathbf{m} \end{aligned}$$

我們使用類似配方法的方式，試圖將對應項對齊

可得

$$C = aX^T X + \Lambda$$

$$C\mathbf{m} = aX^T Y + \Lambda\boldsymbol{\mu} \Rightarrow m = C^{-1}(aX^T Y + \Lambda\boldsymbol{\mu})$$

故指數項可整理成

$$\frac{-1}{2}(\mathbf{w}^T C \mathbf{w} - 2\mathbf{w}^T C \mathbf{m} + \mathbf{m}^T C \mathbf{m} - \mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})$$

marginalize 的積分式子會變為

$$\begin{aligned} & \int e^{\frac{-1}{2}(\mathbf{w}^T C \mathbf{w} - 2\mathbf{w}^T C \mathbf{m} + \mathbf{m}^T C \mathbf{m} - \mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})} d\mathbf{w} \\ &= \int e^{\frac{-1}{2}(\mathbf{w}-\mathbf{m})^T C (\mathbf{w}-\mathbf{m}) + \frac{-1}{2}(-\mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})} d\mathbf{w} = \int e^{\frac{-1}{2}(\mathbf{w}-\mathbf{m})^T C (\mathbf{w}-\mathbf{m})} e^{\frac{1}{2}(\mathbf{m}^T C \mathbf{m} - aY^T Y - \boldsymbol{\mu}^T \boldsymbol{\mu})} d\mathbf{w} = e^{\frac{-1}{2}(-\mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})} \int e^{\frac{-1}{2}(\mathbf{w}-\mathbf{m})^T C (\mathbf{w}-\mathbf{m})} d\mathbf{w} \end{aligned}$$

由於積分式內是一個 multivariate Gaussian，故積分後值為 1，上式改寫為

$$e^{\frac{-1}{2}(-\mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})}$$

故

$$\int N(y | X\mathbf{w}, a^{-1}) N(\mathbf{w} | \boldsymbol{\mu}, \Lambda^{-1}) d\mathbf{w} = e^{\frac{-1}{2}(-\mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu})}$$

我們再針對指數項做改寫，希望能寫成 quadratic form，但再修改前，我們先要處理 $\mathbf{m}^T \mathbf{m}$ 這一項

$$\mathbf{m}^T C \mathbf{m}$$

$$\begin{aligned} &= (C^{-1}(aX^T Y + \Lambda\boldsymbol{\mu}))^T C C^{-1}(aX^T Y + \Lambda\boldsymbol{\mu}) = (aX^T Y + \Lambda\boldsymbol{\mu})^T (C^{-1})^T (aX^T Y + \Lambda\boldsymbol{\mu}) = (aY^T X + \Lambda^T \boldsymbol{\mu}^T) C^{-1} (aX^T Y + \Lambda\boldsymbol{\mu}) \\ &= a^2 Y^T X C^{-1} X^T Y + 2aY^T X C^{-1} \Lambda\boldsymbol{\mu} + \boldsymbol{\mu}^T \Lambda^T C^{-1} \Lambda\boldsymbol{\mu} \end{aligned}$$

$$\begin{aligned} -\mathbf{m}^T C \mathbf{m} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu} &= -a^2 Y^T X C^{-1} X^T Y - 2aY^T X C^{-1} \Lambda\boldsymbol{\mu} - \boldsymbol{\mu}^T \Lambda^T C^{-1} \Lambda\boldsymbol{\mu} + aY^T Y + \boldsymbol{\mu}^T \boldsymbol{\mu} \\ &= Y^T (a - a^2 X C^{-1} X^T) Y - 2aY^T X C^{-1} \Lambda\boldsymbol{\mu} + \dots \end{aligned}$$

我們不繼續做常數項式由於剛剛的經驗讓我們知道，後面常數的修正項到最後只會成為 exponential 前面的係數，最後做 normalize 後會再修正，前面的係數是甚麼並不重要。

為了之後推導方便起見，令 $\lambda = a - a^2 X C^{-1} X^T$

和前面推導的方式一樣 $Y^T \lambda Y - 2a\boldsymbol{\mu}^T \Lambda^T C^{-1} X^T Y + \dots = (Y - m)^T C' (Y - m) = Y^T C' Y - 2m^T C' Y + \dots$

故

$$C' = \lambda$$

$$C' m' = aX C^{-1} \Lambda\boldsymbol{\mu} \Rightarrow m' = aC'^{-1} X C^{-1} \Lambda\boldsymbol{\mu} = a\lambda^{-1} X C^{-1} \Lambda\boldsymbol{\mu} = a\lambda^{-1} X (aX^T X + \Lambda)^{-1} \Lambda\boldsymbol{\mu}$$

而根據 Sherman –Morrison

formula

$$C = aX^T X + \Lambda$$

$$\text{則 } C^{-1} = \Lambda^{-1} - \frac{\Lambda^{-1} a X^T X \Lambda^{-1}}{1 + a X \Lambda^{-1} X^T}$$

$$\begin{aligned} CC^{-1} &= (aX^T X + \Lambda)(\Lambda^{-1} - \frac{\Lambda^{-1} a X^T X \Lambda^{-1}}{1 + a X \Lambda^{-1} X^T}) \\ &= aX^T X \Lambda^{-1} - \frac{aX^T X \Lambda^{-1} a X^T X \Lambda^{-1}}{1 + a X \Lambda^{-1} X^T} + I - \frac{\Lambda \Lambda^{-1} a X^T X \Lambda^{-1}}{1 + a X \Lambda^{-1} X^T} = aX^T X \Lambda^{-1} - \frac{aX^T (I + X \Lambda^{-1} a X^T) X \Lambda^{-1}}{1 + a X \Lambda^{-1} X^T} + I \\ &= aX^T X \Lambda^{-1} - aX^T X \Lambda^{-1} + I = I \end{aligned}$$

為方便起見，

$$\text{令 } \alpha = X \Lambda^{-1} X^T$$

$$C^{-1} = \Lambda^{-1} - \frac{\Lambda^{-1} a X^T (X \Lambda^{-1} X^T (X^T)^{-1})}{1 + a \alpha} = \Lambda^{-1} - \frac{\Lambda^{-1} a X^T \alpha (X^T)^{-1}}{1 + a \alpha}$$

代入 λ 得

$$\begin{aligned} \lambda &= a - a^2 X C^{-1} X^T = a - a^2 X (\Lambda^{-1} - \frac{\Lambda^{-1} a X^T \alpha (X^T)^{-1}}{1 + a \alpha}) X^T \\ &= a - a^2 (X \Lambda^{-1} X^T - X \frac{\Lambda^{-1} a X^T \alpha (X^T)^{-1}}{1 + a \alpha} X^T) \\ &= a - a^2 (\alpha - X \frac{\Lambda^{-1} a X^T \alpha}{1 + a \alpha}) = a - a^2 (\alpha - \frac{a \alpha^2}{1 + a \alpha}) = a - a^2 \frac{\alpha}{1 + a \alpha} \\ &= \frac{a + a^2 \alpha - a^2 \alpha}{1 + a \alpha} = \frac{a}{1 + a \alpha} \end{aligned}$$

$$\text{則 } \lambda^{-1} = \frac{1 + a \alpha}{a} = \frac{1}{a} + \alpha = \frac{1}{a} + X \Lambda^{-1} X^T$$

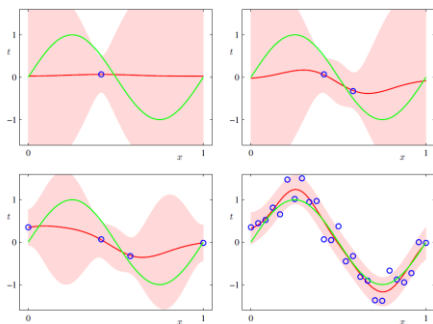
則

$$\begin{aligned} m^T &= a \lambda^{-1} X C^{-1} \Lambda \mu = (a \lambda^{-1} X C^{-1} \Lambda \mu)^T = a \mu^T \lambda^{-1} \Lambda C^{-1} X^T = a \mu^T \lambda^{-1} \Lambda (\Lambda^{-1} - \frac{\Lambda^{-1} a X^T \alpha (X^T)^{-1}}{1 + a \alpha}) X^T = a \mu^T \lambda^{-1} (X^T - \frac{a X^T \alpha}{1 + a \alpha}) = a \mu^T \lambda^{-1} X^T \frac{1}{1 + a \alpha} \\ &= a \mu^T (\frac{1}{a} + \alpha) X^T \frac{1}{1 + a \alpha} = a \mu^T \frac{1 + a \alpha}{a} X^T \frac{1}{1 + a \alpha} = \mu^T X^T \end{aligned}$$

最終，做 marginalize 後的分布為

$$N(\mu^T X^T, \frac{1}{a} + X \Lambda^{-1} X^T) = N(X \mu, \frac{1}{a} + X \Lambda^{-1} X^T)$$

課本 p157



原始是綠線，若只做 **MAP**，只會得到紅線，在點很少時，我們的信心較不足(**co-variance** 較大)，可看到紅色區間的範圍較大，當點變多的時候，信心較夠，紅色區間就會縮小